UNIVERSITÉ DU LITTORAL CÔTE D'OPALE

Licence 3 Informatique
Informatique Théorique 3
2024-2025

TP1 — Alignement de séquences

L'objectif de ce TP est d'implémenter l'algorithme de Needleman-Wunsch pour l'alignement global de séquences deux à deux. Langage : C++ ou python.

Question 1

Mettre en place une fonction permettant de charger une séquence d'ADN fournie dans un fichier. Cette fonction sera utilisée pour charger chaque séquence nécessaire à la suite du TP.

Question 2

Mettre en place une fonction permettant de charger une matrice de substitution fournie en fichier. On considère que les cases sont toujours ordonnées de la manière suivante : - A C G T. La correspondance indice/caractère sera gérée dans la suite du TP.

Question 3

Implémenter la fonction permettant de remplir la matrice des scores utilisée pour retrouver l'alignement optimal des deux séquences adn_1 et adn_2. Cette fonction prend en argument les deux séquences à aligner ainsi que la matrice de substitution (nécessaire pour attribuer les scores). Pour simplifier l'utilisation de la matrice de substitution vous pouvez créer une fonction qui faire correspondre les caractères aux indices (par exemple '-' correspond à 0, 'A' correspond à 1, ...).

Vous pouvez implémenter la fonction vue en cours de manière itérative, en remplissant dans l'ordre :

- la case (0,0) (qui correspond à la case '-','-')
- la première ligne (qui correspond aux scores entre la séquence 1 et les gaps)
- la première colonne (qui correspond aux scores entre la séquence 2 et les gaps)
- le reste des cases au moyen de boucles imbriquées.

Attention, la matrice de score est de taille $(len(adn_1) + 1) * (len(adn_2) + 1)$ pour prendre les gaps en compte.

Question 4

Implémenter la fonction permettant de retourner tous les alignements optimaux des séquences adn_1 et adn_2 (avec gaps). Cette fonction prend en argument les deux séquences à aligner, la matrice de substitution et la matrice de scores. Vous pouvez réutiliser la fonction de correspondances caractères/indices. La fonction retournera une liste qui contiendra des listes de deux séquences afin de pouvoir retourner tous les alignements co-optimaux.

Pour pouvoir reconstituer les alignements, vous pouvez implémenter une matrice qui indique pour la matrice de score à partir de quelle case chaque valeur a été obtenue. Cette matrice correspondrait à celle avec les flèches de direction fournie dans le TD1.

A partir de cette matrice, vous pouvez déterminer l'ensemble des chemins correspondant à des alignements co-optimaux.

Ainsi, vous pourrez utiliser chaque chemin pour reconstituer les alignements de séquences co-optimaux.

Question 5

(Exercice bonus) Adapter votre code pour faire un alignement local de deux séquences. Cet algorithme ressemble fortement à celui de Needleman-Wunsch, avec les exceptions suivantes :

- Les valeurs négatives de la matrice de score sont remplacées par 0,
- l'alignement est effectué en partant de la case de la matrice de score ayant la valeur la plus élevée,
- le processus d'alignement se termine lorsque la valeur 0 est rencontrée dans la matrice de score.